PORT VESSEL MATCHING AI

불완전한 항만 기록을 표준 선박 카탈로그에 연결하는
후보 검색 + Learning-to-Rank 시스템

권준 · AI / ML Portfolio

2026 항만 문제해결을 위한 AI 기술 공모전

78,595
catalog vessels

0.9951
Candidate Recall@600

0.6811
weighted local validation

문제 정의

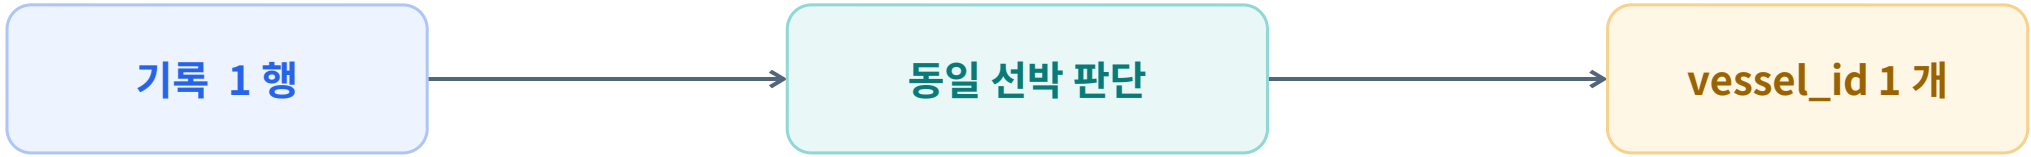
표기가 다른 입출항 기록에서 동일 선박의 vessel_id 를 찾아야 한다

입출항 기록

SUN FLOWER 2
총톤수 12,410
일부 제원 누락

표준 선박 카탈로그

SUNFLOWER II
총톤수 12,398
vessel_id = ?



- 한글 · 영문 · 약칭과 철자 변형
- 동명 선박과 톤수 오차
- 결측치가 있는 제원 정보

Source: DACON competition overview

데이터와 평가 제약

정확도뿐 아니라 코드 제출 환경과 재현성까지 평가 대상이었다

데이터	규모	역할
train.csv	12,222 × 9	입출항 기록 + 정답 ID
vessel_catalog.csv	78,595 × 8	표준 선박 후보
test.csv	비공개	평가 서버에서만 제공

원본 데이터와 식별정보는 GitHub 에 포함하지 않음

평가식

0.7 × 한글 정확도
+ 0.3 × 비한글 정확도

- 외부 선박 데이터 사용 금지
- 인터넷 차단 환경에서 추론
- 모델 · 코드 · 패키지를 ZIP 제출
- 행 수와 sample_id 고정 금지

Source: DACON data / evaluation / rules

완전 일치가 실패하는 이유

이름과 제원을 함께 비교해야 같은 선박을 안정적으로 구분할 수 있다

	기록		카탈로그 후보
한글 표기	오션스타		OCEAN STAR
공백 · 기호	BLUE-MARU		BLUE MARU
철자 변형	HANJIN SEUL		HANJIN SEOUL
제원 오차	12,410 GT		12,398 GT
동명 선박	SUNRISE		SUNRISE × 7

문자열 후보 검색으로 범위를 줄이고 , 톤수 · 국적 · 선종으로 최종 구분

Synthetic examples for explanation

선박 단위 홀드아웃 검증

행 단위 분할의 암기 효과를 제거하고 미관측 선박 검색 능력을 측정했다

행 단위 분할

동일 vessel_id 의 다른 기록이
학습과 검증에 함께 존재

1.000

반복 선박 직접 조회 정확도

실제 일반화 성능을 과대평가

vessel_id-disjoint 분할

정답 선박 ID 가 학습과 검증에
한 건도 겹치지 않도록 분리

0

학습 · 검증 vessel_id 중복

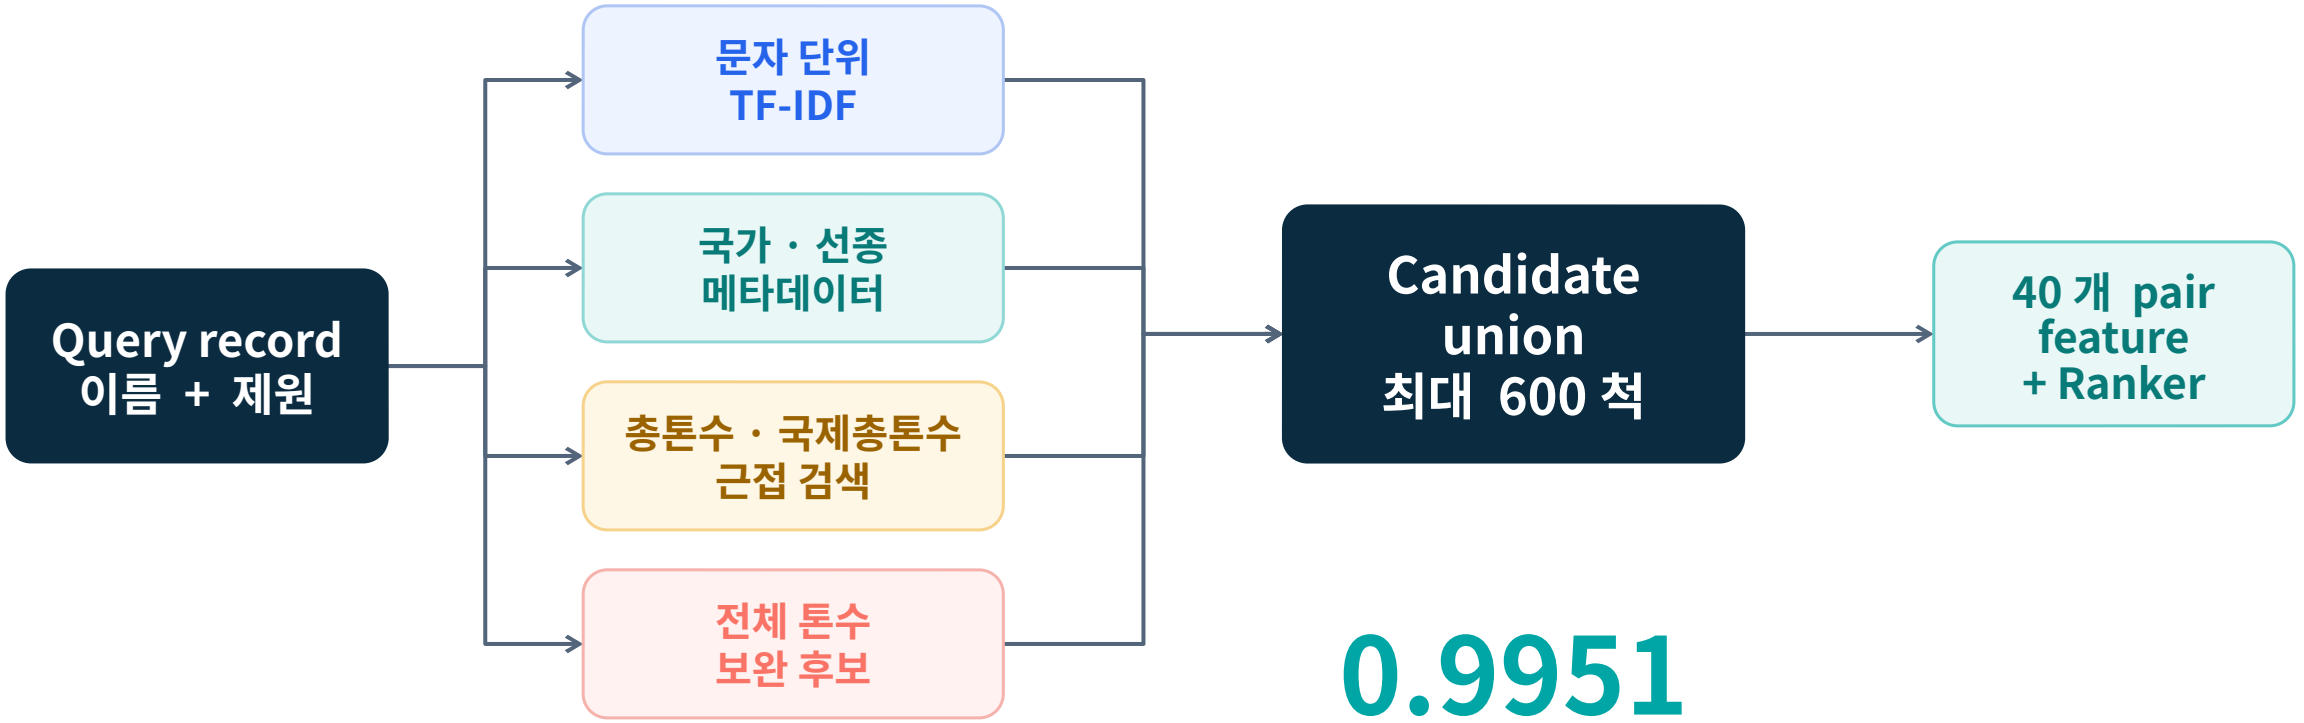
9,752 train rows · 2,470 valid rows

검증 설계가 모델 선택보다 먼저였다

Source: local validation summary

후보 검색 구조

78,595 척 전체를 정밀 비교하지 않고 최대 600 척으로 줄였다



0.9951

Overall Recall@600

후보 단계에서 정답이 빠지면 Ranker 도 복구할 수 없다

Source: candidate retrieval validation

Pair feature 와 Hard Negative

검색 상위의 헷갈리는 오답을 학습해 후보 순위를 직접 최적화했다

문자열 유사도

- exact / ratio / partial / WRatio
- bigram·trigram Jaccard
- 접두어와 길이 유사도

선박 제원

- 총톤수 · 국제총톤수 상대 오차
- 로그 절대 차이
- 국적 · 선종 일치 여부

검색 · 통계 특징

- 검색 순위와 역순위
- 메타데이터 조합 빈도
- 카탈로그 제원 비율

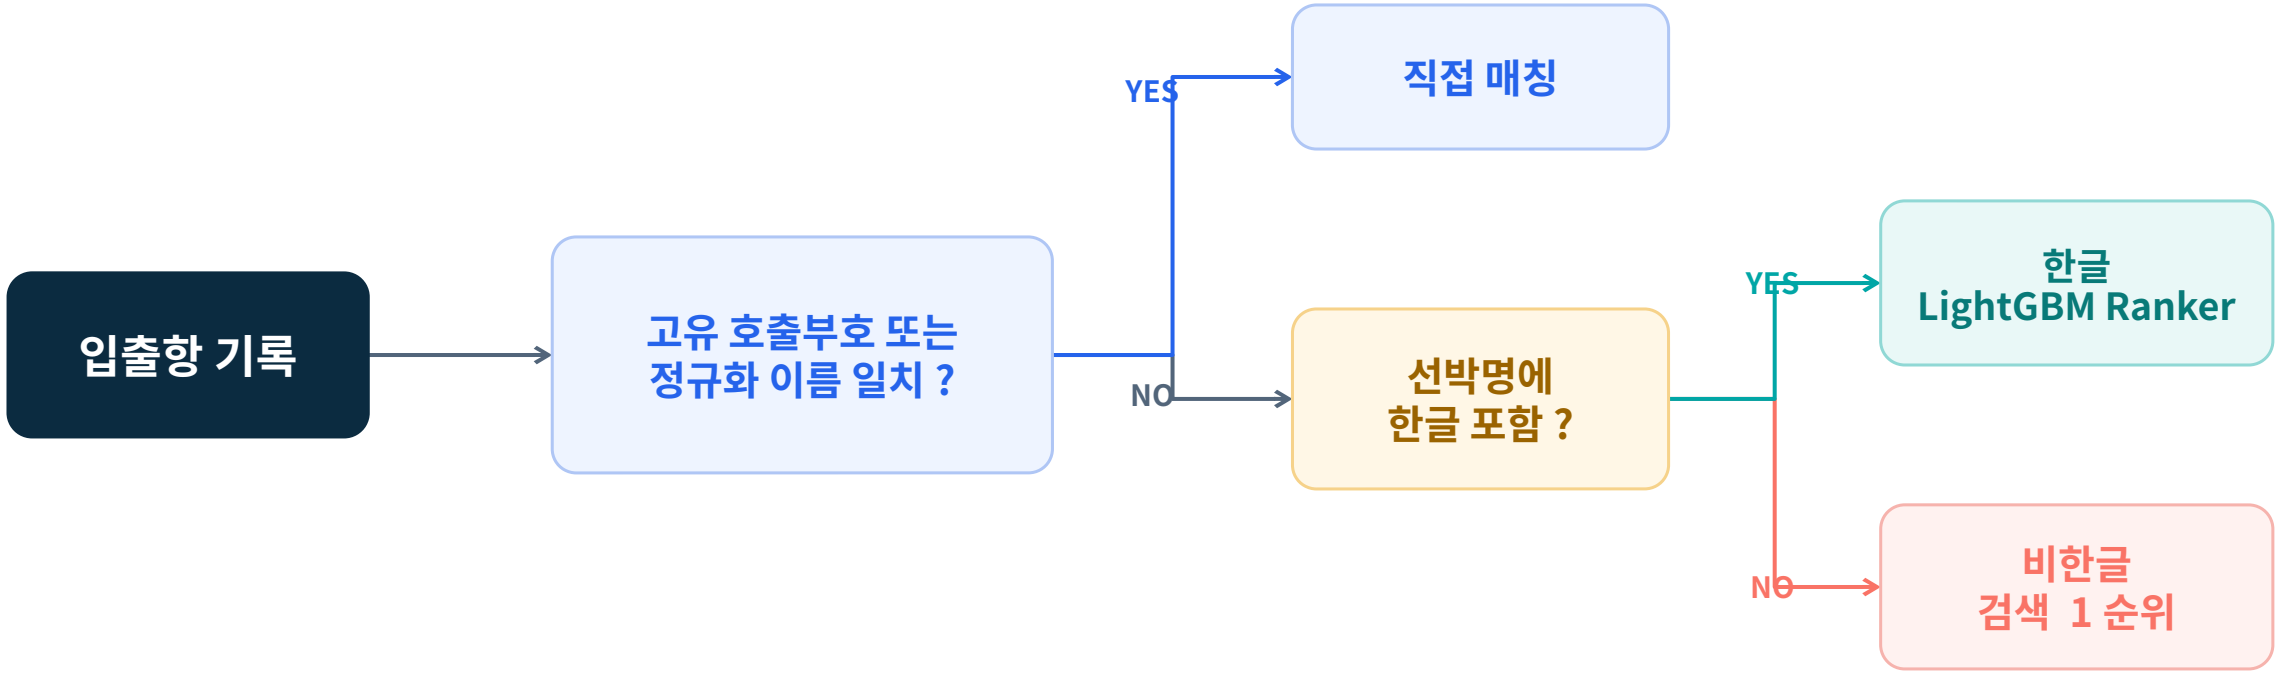
40	40	501,102	5,851
pair features	hard negatives / query	final training pairs	target vessel IDs

LightGBM LambdaRank · 500 trees · learning rate 0.035 · 63 leaves

Source: model_metadata.json

언어별 Hybrid 전략

한글과 비한글 기록에서 서로 다른 강점을 보인 모델을 결합했다



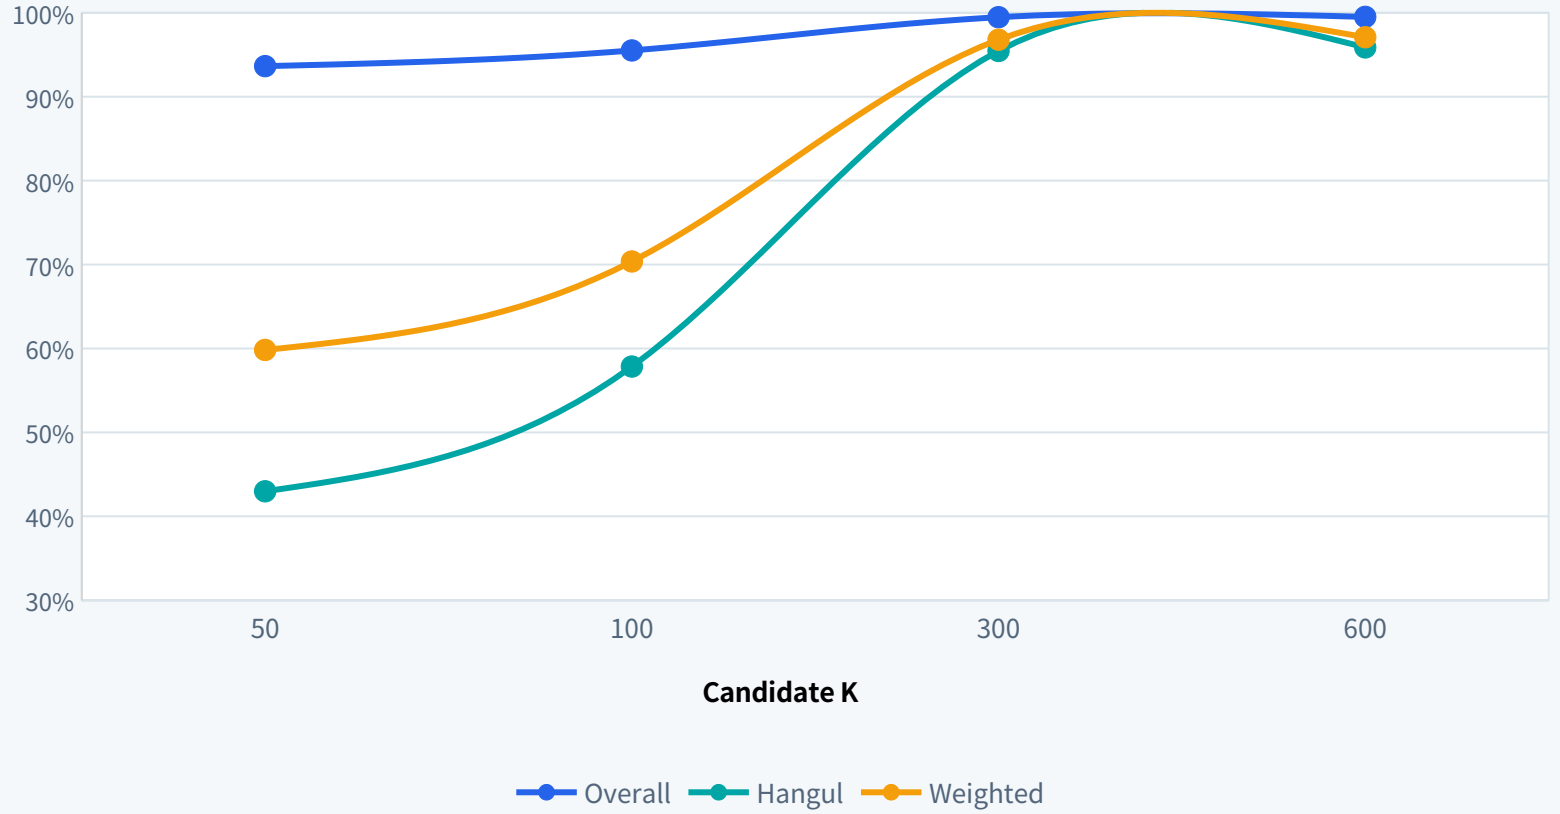
0.6811

official weighted local validation

Source: ranker validation + model metadata

후보 수에 따른 Recall

K=300 이후 전체 Recall 은 포화됐지만 한글 누락을 줄이기 위해 600 개를 유지했다



99.51%

overall Recall@600

95.87%

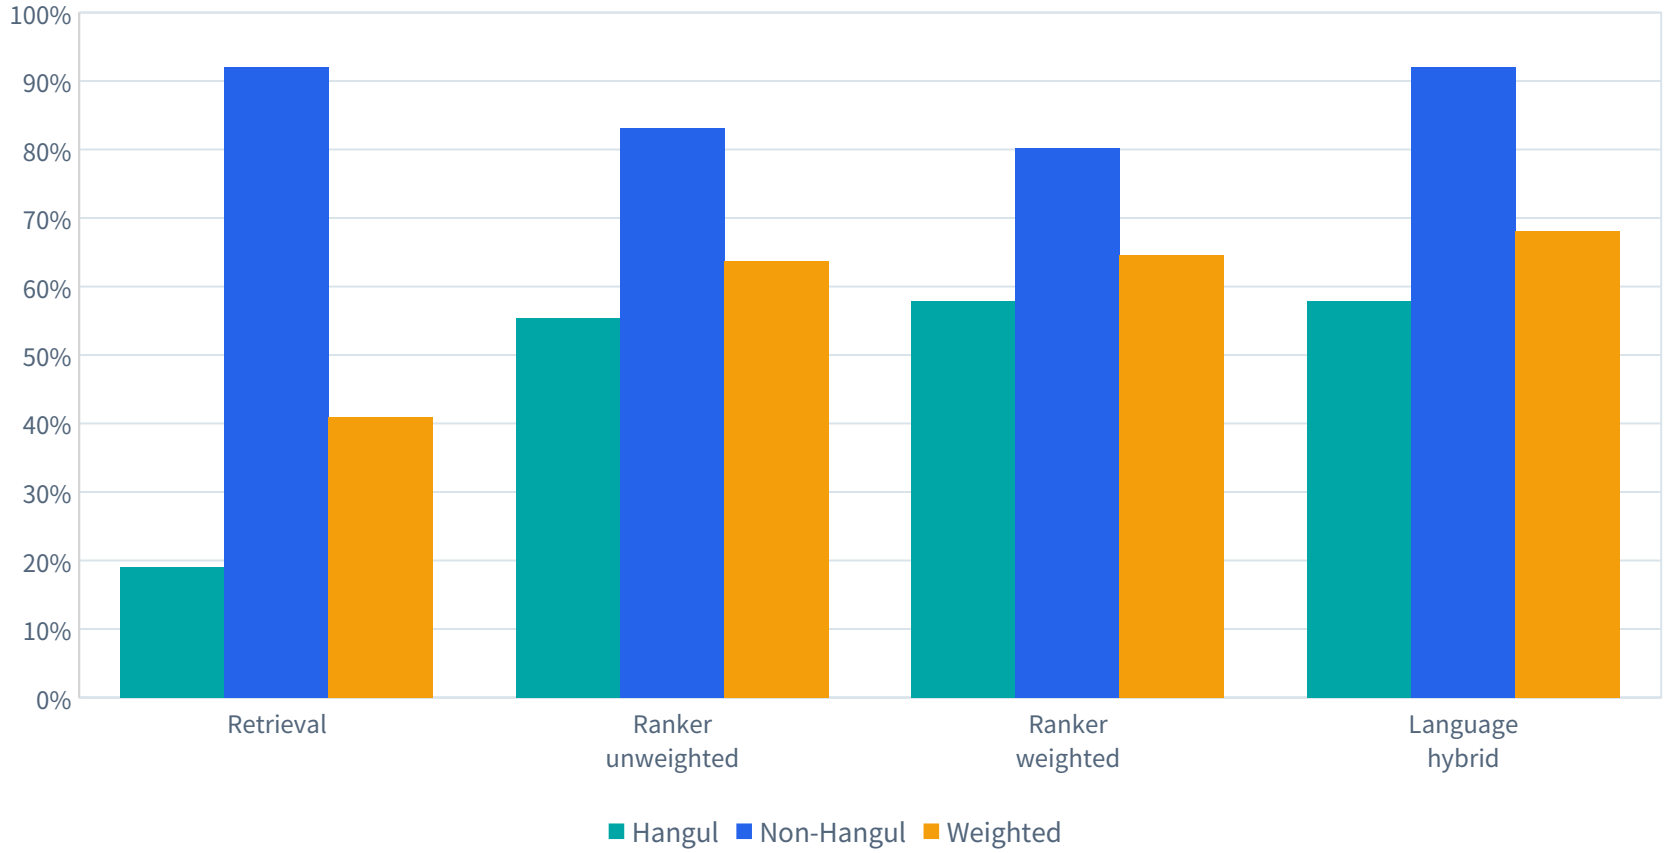
Hangul Recall@600

정답 포함률이 랭커의 성능 상한

Source: candidate retrieval validation

모델 전략 비교

Language Hybrid 가 한글 Ranker 와 비한글 검색의 강점을 함께 유지했다



+0.2719

Retrieval 대비
가중 점수 개선

0.6811

최종 가중
로컬 검증 점수

Source: ranker validation summary

코드 제출과 재현성

학습 코드와 평가 서버 추론 코드를 분리해 오프라인 실행을 검증했다

submit.zip

```
├── model/
│   ├── ranker_model.txt
│   └── model_metadata.json
├── script.py
└── requirements.txt
```

557 KB
compressed submission

1.44 MB
ranker model

평가 서버 대응

- data/test.csv 와 vessel_catalog.csv 를 상대 경로로 읽음
- sample_id 와 행 수를 코드에 고정하지 않음
- 인터넷 없이 저장된 모델을 로드해 추론
- output/submission.csv 형식 자동 검증
- 기본 설치 패키지를 활용해 설치 충돌 최소화

seed · 입력 순서 불변성 · 데이터 SHA-256 · 모델 메타데이터 기록

Source: final submit.zip + model metadata

프로젝트에서 증명한 역량

- 데이터 누수를 고려한 검증 설계
- 대규모 카탈로그의 후보 검색과 재순위화
- 평가식에 맞춘 그룹별 오류 분석
- 제한된 서버 환경을 고려한 추론 패키징

Candidate Recall@600 0.9951

Local weighted validation 0.6811

다음 개선

- 한글 선박명 음역 학습
- 학습형 dense retrieval
- Top-k 추천과 신뢰도 보정
- 검수 근거를 제공하는 운영 화면

GitHub

github.com/junkwon0825/port-vessel-matching-ai